Evaluación por prompts: una alternativa a los pull requests para evaluar el proceso de aprendizaje en la era de la IA generativa

Gutierrez Miranda, J. M.

2026-09-02

La aparición de asistentes de programación basados en modelos de lenguaje (ChatGPT, Copilot, Claude) desacopla el código entregado del aprendizaje del estudiante: dos alumnos pueden entregar código idéntico habiéndolo comprendido de forma muy distinta. En un curso de programación esto erosiona la validez de evaluar el *producto* (el código) y hace ineficiente la revisión línea a línea del *pull request*. Este trabajo propone desplazar la evaluación del producto al **proceso**: en lugar de revisar código, se evalúan los *prompts* que el estudiante dirigió a la IA, sus capturas de la interacción y un *blueprint* técnico final. Se describe una implementación abierta —una acción de integración continua que cierra automáticamente los *pull requests*, una plantilla de documentación de prompts y un evaluador heurístico— desplegada en un curso de Big Data con Python (230 horas, 18 estudiantes), donde la evaluación de las entregas pasó de varias horas a decenas de minutos. Se discuten las limitaciones (la detección de prompts fabricados es heurística y evitable; la evidencia procede de un único despliegue) y las implicaciones de privacidad y consentimiento. La contribución es de práctica: un método y un conjunto de herramientas reproducibles, no un estudio controlado de resultados de aprendizaje.

1 Introducción

Desde la difusión masiva de asistentes de programación basados en modelos de lenguaje a finales de 2022, evaluar código como evidencia de aprendizaje presenta un problema de validez. El código puede generarse a partir de una instrucción en lenguaje natural, de modo que el artefacto entregado ya no informa de forma fiable sobre lo que el estudiante comprende. Dos entregas idénticas pueden corresponder a dos procesos de aprendizaje opuestos: una copia sin comprensión y una construcción razonada.

En la enseñanza de la programación esto se manifiesta en el *pull request* (PR), el mecanismo habitual por el que un estudiante propone su trabajo. Revisar un PR línea a línea busca juzgar la calidad del código; pero si el código puede ser generado, esa revisión mide el resultado, no el proceso, y además escala mal: decenas de entregas con código similar consumen muchas horas de corrección con poca información diagnóstica.

Este trabajo propone y documenta una alternativa: **evaluar el proceso** mediante los *prompts* que el estudiante dirigió a la IA, en lugar del código resultante. No se prohíbe el uso de la IA —se asume legítima, como una herramienta profesional— y se traslada la evaluación a cómo se la utilizó.

2 Marco: del producto al proceso

La idea se apoya en tres nociones establecidas de la evaluación educativa. La **evaluación auténtica** sostiene que las tareas deben capturar desempeños significativos y no solo respuestas verificables (Wiggins 1990). El desarrollo del **juicio evaluativo** —la capacidad del estudiante de valorar la calidad de su propio trabajo y el ajeno— se propone como competencia central de la educación superior (Tai et al. 2018). Y la revisión de la **taxonomía de Bloom** distingue el recordar y aplicar de analizar, evaluar y crear (Anderson and Krathwohl 2001): en la era de la IA, el nivel cognitivo relevante se desplaza hacia la formulación de buenas preguntas y la valoración crítica de las respuestas.

La preocupación por la integridad académica ante la IA generativa está documentada (Cotton et al. 2024); la propuesta de este trabajo no es de vigilancia sino de rediseño: si el producto ya no discrimina el aprendizaje, se evalúa el proceso que lo genera. La analogía profesional es directa: en el desarrollo de software, el valor no está solo en el código sino en las decisiones y el porqué que lo sustentan (Hunt and Thomas 2019).

3 El sistema

El método se articula en tres componentes, publicados como herramientas abiertas.

Documentación de prompts. El entregable principal no es el código sino un archivo `PROMPTS.md` que contiene: (i) los *prompts* reales dirigidos a la IA, copiados tal cual —con sus errores de escritura e informalidad—; (ii) capturas de pantalla de las interacciones clave como evidencia; y (iii) un *blueprint* técnico final que la propia IA redacta a petición del estudiante, resumiendo el *stack*, la arquitectura y las decisiones, y que sirve para comprobar que el estudiante comprende lo que construyó.

Cierre de los pull requests. Una acción de integración continua detecta la apertura de cualquier PR, deja un comentario que explica el sistema y lo cierra. El canal de aporte deja de ser el *diff* y pasa a ser la propuesta documentada.

Evaluador heurístico. Un script recorre las entregas y genera un informe con indicadores objetivos —presencia y número de prompts, existencia de capturas y de *blueprint*, extensión del documento— y marca casos para revisión humana. La detección de posibles entregas fabricadas se basa en señales como la ausencia de errores humanos en prompts "demasiado limpios", la coincidencia con el ejemplo del docente o la incoherencia entre el *blueprint* y el código.

4 Despliegue

El sistema se aplicó en un curso de **Big Data con Python** de 230 horas con **18 estudiantes** universitarios. La evaluación de las 18 entregas finales, que con revisión de PRs requería varias horas, se realizó en el orden de media hora, interviniendo el docente de forma manual solo en los casos marcados por el evaluador. Este resultado se reporta como **experiencia de despliegue**, no como medida de un estudio controlado: no se compararon resultados de aprendizaje ni se estimó la fiabilidad de la evaluación (ver Section 6).

5 Ética y privacidad

El método pide a los estudiantes publicar prompts y capturas en un repositorio público, lo que exige cautelas. Debe obtenerse **consentimiento informado** y ofrecerse una alternativa privada (repositorio privado o entrega por el aula virtual) para quien no desee exponer su trabajo. Las capturas pueden contener datos personales (nombre, correo, interfaz de la cuenta), por lo que se indica a los estudiantes que los **oculten**. La aplicación debe cumplir la normativa de protección de datos de la institución (RGPD en la Unión Europea, FERPA en Estados Unidos) y acordar la retención y retirada de los trabajos a petición del estudiante.

6 Limitaciones y trabajo futuro

La detección de prompts fabricados es **heurística y evitable**: un estudiante puede pedir a la IA que introduzca erratas para simular espontaneidad. Por ello las alertas deben tratarse como señales para la revisión en persona, no como veredictos. La evidencia de eficacia procede de un **único despliegue** y no sustituye a un estudio con datos de aprendizaje, tasa de falsos positivos y validez de la evaluación. El trabajo futuro pasa por: recoger de forma sistemática las calificaciones y una encuesta a los estudiantes; estimar la concordancia entre evaluadores; y contrastar la evaluación por prompts con medidas independientes de comprensión.

7 Conclusión

Cuando el producto deja de discriminar el aprendizaje, evaluar el proceso recupera la validez de la evaluación. Documentar y valorar los prompts —las preguntas que el estudiante sabe hacer— convierte el uso de la IA de amenaza a objeto de evaluación, y hace la corrección escalable. La propuesta se ofrece como método y conjunto de herramientas reproducibles para la comunidad educativa, a la espera de la evidencia empírica que un estudio controlado deberá aportar.

Disponibilidad

El código y los materiales están disponibles bajo licencia MIT en https://github.com/TodoEconometria/evaluacion-prompts-ia.

Referencias

Anderson, Lorin W., and David R. Krathwohl, eds. 2001. *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives*. Longman.

Cotton, Debby R. E., Peter A. Cotton, and J. Reuben Shipway. 2024. "Chatting and Cheating: Ensuring Academic Integrity in the Era of ChatGPT." *Innovations in Education and Teaching International* 61 (2): 228–39. https://doi.org/10.1080/14703297.2023.2190148.

Hunt, Andrew, and David Thomas. 2019. *The Pragmatic Programmer: Your Journey to Mastery*. 20th Anniversary. Addison-Wesley.

Tai, Joanna, Rola Ajjawi, David Boud, Phillip Dawson, and Ernesto Panadero. 2018. "Developing Evaluative Judgement in Higher Education: Assessment for Knowing and Producing Quality Work." *Higher Education* 76 (3): 467–81. https://doi.org/10.1007/s10734-017-0220-3.

Wiggins, Grant. 1990. "The Case for Authentic Assessment." *Practical Assessment, Research, and Evaluation* 2 (2).